Netflix Prize Data Mining Project – 5 人分工计划

总览

项目需要完成：(1) EDA、(2) Recommendation Engine、(3) Clustering、(4) RFM Analysis、(5) 简报与整合。5 人可以高度并行化，只有一个共同前置作业：**数据加载 (Data Loading)**，需最先完成，其余 4 大区块可同步进行。

时间轴与依赖关系

Person A – 数据工程 + EDA（评分 & 时间维度）

角色：Data Engineer / EDA Lead (Rating & Temporal)

职责：

1. **数据加载 Pipeline（最优先，Day 1-2）**

- 撰写 `01_data_loading.ipynb`
- 解析 `dataset/training_set/` 下 17,770 个 `mv_*.txt` 文件，合并为一个 DataFrame（列：`MovieID, CustomerID, Rating, Date`）
- 与 `dataset/movie_titles.txt` 合并取得 `YearOfRelease, Title`
- 转换 `Date` 为 datetime，萃取 `Year`, `Month`, `DayOfWeek`
- 储存为 `data/ratings.parquet`（供全组使用）
- 解析 `dataset/probe.txt` 为 probe DataFrame，也存成 Parquet
- **这是所有人的前置依赖，必须最先完成并通知全组**

1. **EDA – 评分分布 & 时间趋势（Day 3-5）**

- 在 `02_eda.ipynb` 中负责以下小节：
  - Section 2.1: Rating Distribution Analysis（整体评分直方图、按年份分布、按电影上映年份）
  - Section 2.4: Temporal Patterns（月度评分量时序图、评分均值随时间漂移、月份 x 年份 heatmap）
- 使用 `matplotlib`, `seaborn`, `plotly`

1. **EDA 整合美化（Day 6-7）**

- 收集 Person B 的 EDA 部分，合并到 `02_eda.ipynb`
- 统一图表风格、加上小结文字

产出物： `01_data_loading.ipynb`, `data/ratings.parquet`, `02_eda.ipynb`（Section 2.1, 2.4 + 最终整合）

Person B – EDA（用户 & 电影维度 + 统计）

角色：EDA Analyst (User & Movie Behavior)

职责：

1. **EDA – 用户行为分析（Day 3-5）**

- 在 `02_eda.ipynb` 的独立区块（或先在自己的 notebook 写，最后合并）：
  - Section 2.2: User Behavior Analysis
    - 每位用户评分数量分布（log-scale histogram）
    - 每位用户平均评分分布
    - Power-law 分析：少数用户贡献多数评分
    - 用户活跃时间线（星期几、月份、年度趋势）

1. **EDA – 电影人气分析（Day 3-5，与上面并行）**

- Section 2.3: Movie Popularity Analysis
  - 每部电影评分数量分布
  - Top 20 最多评分 vs. Top 20 最高评分（设最低门槛）
  - Long-tail 分析
  - 评分数 vs. 平均评分散点图

1. **EDA – 统计相关性分析（Day 6-7）**

- Section 2.5: Correlation and Statistical Tests
  - 电影年龄 vs. 平均评分的相关性
  - 评分数量 vs. 平均评分的相关性
  - 统计摘要表格

产出物： `02_eda.ipynb` 中的 Section 2.2, 2.3, 2.5（交给 Person A 整合）

Person C – Recommendation Engine（协同过滤）

角色：ML Engineer (Collaborative Filtering)

职责：

1. **Baseline 与 Bias 模型（Day 3-4）**

- 撰写 `03_recommendation_engine.ipynb`
- Section 3.1: Baseline Model
  - Global Mean 预测
  - User + Movie Bias Model: `pred = global_mean + user_bias[u] + movie_bias[m]`
  - 在 probe set 上计算 RMSE

1. **矩阵分解 SVD（Day 5-7）**

- Section 3.2: Matrix Factorization
  - 使用 `surprise` 函数库（`SVD`, `SVDpp`, `NMF`）
  - 超参数调校：latent factors (20, 50, 100)、learning rate、regularization
  - Cross-validation 或 train/probe split

1. **邻近方法 & 模型比较（Day 8-9）**

- Section 3.3: Neighborhood-Based CF
  - User-based CF（cosine similarity, top-K）
  - Item-based CF
  - 使用 `surprise.KNNBaseline`
- Section 3.4: Evaluation
  - RMSE / MAE 在 probe set 的比较表格
  - 目标：打败 Netflix Cinematch baseline RMSE ~0.9514

产出物： `03_recommendation_engine.ipynb`（完整的模型训练、评估、比较表）

Person D – Clustering（用户 & 电影聚类）

角色：ML Engineer (Clustering & Segmentation)

职责：

1. **Feature Engineering（Day 3-4）**

- 撰写 `04_clustering.ipynb`
- Section 4.1: 建立特征
  - User features: 评分数量、平均评分、标准差、日期范围、最常给的评分、5星比例
  - Movie features: 评分数量、平均评分、标准差、上映年份、偏度

1. **K-Means + PCA 聚类（Day 5-7）**

- Section 4.2: User Clustering
  - `StandardScaler` 标准化
  - PCA 降到 2-3 维可视化
  - K-Means（Elbow method + Silhouette score 选 K，预期 4-6）
  - 解释集群：「严格批评者」、「慷慨评分者」、「随意用户」、「重度用户」
- Section 4.3: Movie Clustering
  - 电影特征向量（评分统计 + 年份 + 评分分布）
  - K-Means 或 Hierarchical clustering
  - Dendrogram 可视化

1. **进阶分析（Day 8-9）**

- Section 4.4: DBSCAN 找离群用户/电影
- t-SNE 高维可视化
- K-Means vs. Hierarchical vs. DBSCAN 结果比较

产出物： `04_clustering.ipynb`（含特征工程、多种聚类方法、可视化、集群解释）

Person E – RFM Analysis + 简报 + 项目整合

角色：Business Analyst / Project Integrator

职责：

1. **RFM 分析（Day 3-6）**

- 撰写 `05_rfm_analysis.ipynb`
- Section 5.1: RFM 指标定义
  - Recency (R): 距最近一次评分的天数（以 2005-12-31 为基准）
  - Frequency (F): 评分总数
  - Monetary (M): 平均评分（作为互动品质的代理指标）
- Section 5.2: RFM 打分
  - 五分位数 (quintile) 打分 1-5
  - 建立 composite RFM score
  - 用户分群：Champions、At Risk、Lost、Loyal 等
- Section 5.3: RFM 可视化
  - 3D scatter plot（R, F, M 依 segment 上色）
  - Segment 数量 heatmap
  - 各 segment 的 R/F/M box plot

    - Treemap 或 bar chart 显示各 segment 大小
- Section 5.4: 商业洞察
    - 针对每个 segment 提出可执行建议
    - 交叉比对 Person D 的 clustering 结果

1. **简报制作（Day 7-9）**

- 建立投影片（7 大区块）：

1. Title + Team
2. Business Problem + Dataset Overview
3. EDA Highlights（从 Person A/B 挑 4-5 张最佳图表）
4. Recommendation Engine（Person C 的模型比较表 & RMSE）
5. Clustering（Person D 的可视化 & 集群解释）
6. RFM Analysis（自己的 segmentation & business insights）
7. Conclusions + Future Work
8. **项目整合（Day 8-9）**

- 撰写 `requirements.txt`（pandas, numpy, matplotlib, seaborn, plotly, scikit-learn, scikit-surprise, scipy, pyarrow, tqdm）
- 撰写 `README.md`（项目简介、数据来源、如何执行、团队成员）
- 确保所有 notebook 可顺利从头到尾执行
- 统一 notebook 的 markdown 说明风格

产出物： `05_rfm_analysis.ipynb`, 简报投影片, `requirements.txt`, `README.md`

并行化摘要

时间区间	Person A	Person B	Person C	Person D	Person E
Day 1-2	**数据加载** (blocker)	阅读文献、规划 EDA	阅读 surprise 文档	设计 feature schema	规划 RFM 指标
Day 3-5	EDA: 评分 + 时间	EDA: 用户 + 电影	Baseline + SVD	Feature Eng + KMeans	RFM 计算 + 打分
Day 6-7	EDA 整合美化	EDA 统计分析	SVD 调参	PCA + 进阶聚类	RFM 可视化 + 洞察
Day 8-9	Code review	Code review	CF 比较表	DBSCAN + t-SNE	**简报 + 整合**

关键协作点

- **Day 2 结束**：Person A 必须产出 `data/ratings.parquet`，放入共享文件夹或 Git repo，通知全组
- **Day 7 结束**：Person B 将 EDA 片段交给 Person A 整合；Person D 将 clustering 结果分享给 Person E 做交叉比对
- **Day 9 结束**：Person C、D 各将 notebook 最终版交给 Person E 做简报整合
- 建议使用 **Git** 管理代码，每人开自己的 branch，最后由 Person E merge